



Haladó adatelemzési labor

Csapattagok: Szendrey Máté

Nagy Csaba Dániel

Sütő István

Konzulens: Tumay Ádám

GT értékelés terv

A rendszer kiértékelését három szinten érdemes elvégezni: külön a fogdetektáló modellen, külön a klasszifikációs modellen, majd a teljes kétfélepcsős pipeline-on. Erre azért van szükség, mert a végső hiba több forrásból származhat: a fog nem kerül detektálásra, rossz fog kerül kivágásra, vagy a helyesen kivágott fogat ítéli meg rosszul a klasszifikációs modell.

1. Fogdetektáló modell kiértékelése

A YOLO modell esetében két külön feladatot kell értékelni, mert a rendszerterv alapján még döntési pont, hogy a modellnek csak fogakat kell-e lokalizálnia, vagy konkrét fogazonosító címkéket is megbízhatóan kell-e rendelnie hozzájuk.

1.1. Fogak bounding box szintű lokalizációja

Ebben az értékelésben a modell feladata az, hogy minden fogat bounding box-szal körberajzoljon, függetlenül attól, hogy pontosan melyik fogról van szó. Itt minden annotált fog azonos „fog” osztályként kezelhető.

A legfontosabb metrikák:

Recall

Azt mutatja meg, hogy az annotált fogak mekkora részét találja meg a modell. Ennél a feladatnál ez kiemelten fontos, mert ha egy fog kimarad a detektálásból, akkor a klasszifikációs modellhez sem jut el, így a szuvasodás felismerése lehetetlenné válik.

Precision

Azt jelzi, hogy a modell által detektált bounding boxok mekkora része valóban fog. Ez azért fontos, mert a túl sok téves detekció felesleges vagy hibás kivágásokat eredményezhet, amelyek ronthatják a pipeline végső diagnosztikai pontosságát.

mAP@IoU

A detekció általános minőségét méri különböző vagy rögzített IoU küszöbök mellett. Egyszerre ad képet arról, hogy a modell megtalálja-e a fogakat, illetve mennyire pontosan illeszkednek a prediktált bounding boxok a valódi annotációkra.

IoU eloszlás

Az Intersection over Union értékek eloszlása megmutatja, mennyire pontosak a bounding boxok geometriailag. Ez különösen fontos, mert a klasszifikációs modell már kivágott fogképeken dolgozik, így egy pontatlan box levághat releváns fogrészeket, vagy túl sok környezeti zajt tartalmazhat.

False Negative elemzés

A kimaradt fogak vizuális és statisztikai elemzése megmutatja, hogy milyen típusú fogaknál hibázik a modell: például kis méretű, részben takart, rossz kontrasztú vagy szélső pozícióban lévő fogaknál. Ez közvetlenül segíti a dataset és az augmentáció javítását.

1.2. Adott címkéjű fog megtalálása

Ebben az értékelésben nem elég az, hogy a modell talál egy fogat, hanem azt is helyesen kell azonosítania, hogy melyik fogról van szó. Ez akkor releváns, ha a rendszernek fogszámozás vagy fogspecifikus diagnózis szintjén is megbízhatóan kell működnie.

A legfontosabb metrikák:

Class-wise recall

Azt mutatja meg, hogy az egyes fogcímkékhez tartozó valódi fogakat milyen arányban találja meg a modell. Ez segít feltárni, hogy vannak-e olyan fogpozíciók, amelyeket a modell rendszeresen kihagy.

Class-wise precision

Azt jelzi, hogy az adott fogcímkével prediktált boxok mekkora része valóban ahhoz a foghoz tartozik. Ez különösen fontos, ha a modell összekeveri a szomszédos vagy szimmetrikus fogakat.

Macro F1-score

Az osztályonkénti precision és recall kiegyensúlyozott átlaga. Azért hasznos, mert nem engedi, hogy a gyakrabban előforduló vagy könnyebben felismerhető fogak dominálják az összképet.

Confusion matrix fogcímkékre

Megmutatja, mely fogakat keveri össze egymással a modell. Ez a modellválasztási döntés szempontjából kulcsfontosságú: ha a címkézett fogdetekció gyenge, de a sima lokalizáció jó, akkor célszerűbb lehet egyetlen „fog” osztályt használni, és a fogazonosítást külön módszerrel vagy utófeldolgozással kezelni.

mAP osztályonként

Azt mutatja meg, hogy az egyes fogcímkék lokalizációja és felismerése együtt mennyire megbízható. Ez átfogó képet ad arról, hogy a címkézett detekció valóban használható-e a pipeline-ban.

2. Klasszifikációs modell kiértékelése

A klasszifikációs modell fő célja annak eldöntése, hogy egy fog szuvas-e vagy sem. Mivel a tanítás történhet többosztályos címkékkel, illetve ezek későbbi összevonásával, a kiértékelést

két nézetben kell elvégezni: többosztályos címkeszinten és bináris szuvas / nem szuvas szinten. A végső döntés szempontjából a bináris értékelés a fontosabb.

A legfontosabb metrikák:

Recall szuvas osztályra

Azt mutatja meg, hogy a valóban szuvas fogak mekkora részét ismeri fel a modell. Ez klinikai szempontból kiemelten fontos, mert a false negative hiba, vagyis egy szuvas fog egészségesnek minősítése, súlyosabb következménnyel járhat, mint egy téves pozitív jelzés.

Precision szuvas osztályra

Azt jelzi, hogy a modell által szuvasnak ítélt fogak mekkora része valóban szuvas. Ez azért fontos, mert a túl sok false positive rontja a modell gyakorlati használhatóságát, és felesleges ellenőrzéseket eredményezhet.

F1-score vagy F β -score

Az F1-score a precision és recall egyensúlyát méri. Ha a cél kifejezetten a szuvas fogak minél biztosabb megtalálása, akkor F β -score használata is indokolt, ahol a recall nagyobb súlyt kap. Ez jobban illeszkedik ahhoz a célhoz, hogy kevés szuvas fog maradjon észrevétlenül.

PR AUC

A Precision–Recall görbe alatti terület különösen hasznos osztályaránytalanság esetén. Ha a szuvas fogak aránya alacsonyabb a datasetben, akkor a PR AUC informatívabb képet adhat a modell teljesítményéről, mint az accuracy vagy akár az ROC AUC.

ROC AUC

Azt mutatja meg, hogy a modell mennyire képes elkülöníteni a szuvas és nem szuvas fogakat különböző döntési küszöbök mellett. Ez a modell diszkriminációs képességét méri, de osztályasszimetria esetén önmagában nem elegendő, ezért a PR AUC-val együtt érdemes értelmezni.

A többosztályos tanítás esetén külön szükséges confusion matrixot készíteni az eredeti címkékre is. Ennek elsődleges célja nem a végső diagnosztikai teljesítmény mérése, hanem annak elemzése, hogy mely osztályok keverednek gyakran. Ez alapján dönthető el, hogy mely címkék összevonása indokolt, és mely finom kategóriák rontják inkább a generalizációt, mintsem hasznos információt adnának.

3. Pipeline szintű kiértékelés

A teljes rendszer értékelésekor a bemenet a teljes panorámakép, a kimenet pedig az, hogy a rendszer mely fogakat jelöli szuvasnak. Ez a legfontosabb gyakorlati értékelési szint, mert itt együtt jelennek meg a detekciós és klasszifikációs hibák.

A pipeline értékelésénél ugyanazt a végső kérdést kell mérni: felismeri-e a rendszer a szuvas fogakat a teljes képen.

A legfontosabb metrikák:

End-to-end recall szuvas fogakra

Azt mutatja meg, hogy a teljes rendszer a valóban szuvas fogak mekkora részét találja meg és minősíti szuvasnak. Ez tartalmazza a detekciós és klasszifikációs hibákat is, ezért közvetlenebbül méri a rendszer gyakorlati használhatóságát, mint a külön modellek metrikái.

End-to-end precision szuvas fogakra

Azt jelzi, hogy a rendszer által szuvasnak jelölt fogak mekkora része valóban szuvas. Ez megmutatja, hogy a teljes pipeline mennyi téves riasztást produkál.

End-to-end F β -score

A precision és recall összevont mutatója a teljes pipeline-ra. Amennyiben a false negative hibák minimalizálása fontosabb, a recallt nagyobb súllyal kezelő F β -score használata indokolt.

Pipeline confusion matrix

Megmutatja, hogy a teljes rendszer milyen típusú hibákat követ el: például nem detektált szuvas fogat, detektált, de egészségesnek minősített szuvas fogat, vagy egészséges fogat tévesen szuvasnak jelölt.

Hibaforrás szerinti bontás

A hibákat külön kell választani aszerint, hogy detekciós vagy klasszifikációs eredetűek. Ez döntéstámogató szerepű: ha sok szuvas fog már a YOLO lépésben kimarad, akkor a detektáló modellt kell javítani; ha a fog helyesen detektálódik, de rossz diagnózist kap, akkor a klasszifikációs modell vagy a kivágási stratégia szorul módosításra.

4. Domain shift validáció (opcionális)

Mivel a klasszifikációs modell nem feltétlenül YOLO által kivágott fogakon tanul, lehet érdemes külön validálni, hogy a modell teljesítménye hogyan változik manuálisan annotált, tiszta fogkivágásokon és YOLO által generált kivágásokon.

Ehhez ugyanazokat a klasszifikációs metrikákat kell összehasonlítani mindkét bemeneti típuson: szuvas recall, precision, F β -score, PR AUC és ROC AUC. Ha a teljesítmény YOLO-kivágásokon jelentősen rosszabb, akkor a probléma nem feltétlenül a klasszifikátor döntési képessége, hanem a bemeneti eloszlás megváltozása. Ilyenkor szükséges lehet a klasszifikációs tanítóadatok kiegészítése YOLO által kivágott mintákkal, a bounding boxok bővítése, vagy a detekciós modell finomítása.

5. Döntési szempontok

A detekciós modell esetében a kiértékelés alapján el kell dönteni, hogy a címkézett fogdetekció elég megbízható-e. Ha az adott címkéjű fogak felismerése lényegesen gyengébb, mint az egyszerű foglokalizáció, akkor célszerűbb az egyosztályos „fog” detekciót használni, és a fogazonosítást nem közvetlenül a YOLO osztálypredikcióra bízni.

A klasszifikációs modell esetében a végső döntési küszöböt nem kizárólag accuracy alapján kell kiválasztani. A fő szempont az, hogy a szuvas fogak recall értéke megfelelő legyen, miközben a precision még elfogadható szinten marad. Emiatt a PR görbe elemzése és a küszöbhangolás fontos része a kiértékelésnek.

A végső rendszer akkor tekinthető stabilnak, ha külön-külön a detekció és a klasszifikáció is megfelelően teljesít, valamint a pipeline szintű eredmények nem mutatnak jelentős romlást a külön komponensek validációjához képest.